LAB 4 - TỔNG HỢP TIẾNG NÓI

Báo cáo thực nghiệm tái lập được. Câu thử: “Moi khach hang so 23 den quay 5.” Chuỗi token sau chuẩn hóa: moi, khach, hang, so, hai, ba, den, quay, nam.

Quan trọng: môi trường hiện không có giọng thu âm hay mô hình TTS neural offline. Inventory trong bài là tín hiệu tổng hợp điều hòa có bao phổ giả lập, chỉ dùng để minh họa xử lý số; không thể xem là lời nói tiếng Việt tự nhiên.

Biểu đồ minh họa: inventory_stats.svg (SVG trong figures/).

1. Chuẩn hóa và inventory

Chuẩn hóa chữ thường, bỏ dấu câu và đọc từng chữ số: 23 → hai ba; 5 → năm. Bộ inventory có 16 từ, mỗi từ hai ứng viên WAV mono PCM 16 kHz, 16-bit. metadata.csv lưu nhãn, speaker giả lập, duration, RMS, đường dẫn và nguồn.

Tín hiệu được tạo bằng chuỗi harmonic có F0 biến thiên và hai vùng cộng hưởng, bao biên đầu/cuối và nhiễu nhỏ. Đây là mô hình nguồn-lọc đơn giản, không phải phát âm từ vựng.

Biểu đồ minh họa: inventory_stats.svg (SVG trong figures/).

2. Baseline nối thô

raw_concat.wav nối candidate 1 bằng cách đặt cạnh trực tiếp. Sai khác pha/biên độ tại điểm nối tạo discontinuity; dạng sóng minh họa trong hình.

best_concat.wav dùng dynamic programming trên hai candidate mỗi token. Join cost là MSE log-magnitude phổ trung bình trong 25 ms ở hai phía điểm nối; thêm phạt duration đơn giản. Sau chọn unit áp dụng cross-fade 15 ms.

Biểu đồ minh họa: waveform_join.svg (SVG trong figures/).

3. Unit selection và smoothing

Bảng unit_selection_cost.csv ghi tổng join cost của baseline và đường đi được chọn. Chỉ số phổ trên tín hiệu giả lập không chứng minh naturalness: không có âm vị hay người nghe.

Cross-fade dùng trộn tuyến tính. 0 ms giữ nguyên biên; 5/15/30 ms cần được nghe trên giọng thật để chọn thỏa hiệp giữa click và làm mờ chuyển tiếp. Trong bộ demo này xuất waveform ở 0 và 15 ms; các độ dài khác là tham số có thể tái chạy.

Biểu đồ minh họa: join_cost.svg (SVG trong figures/).

4. Prosody và HMM quan sát

Xuất các biến thể duration 0.8/1.0/1.2 và pitch −2/0/+2 bán âm; pitch shift bằng đổi tốc độ nội suy nên đồng thời đổi duration và phổ, không phải thuật toán pitch-preserving. Vì vậy đây chỉ là minh họa artifact.

hmm_demo/trajectory.csv chứa F0 và F1 theo frame 10 ms của toy HMM. hmm_tts.wav được tạo từ bộ phát tổng hợp toy; đây không phải model HMM đã huấn luyện. HMM thực tế sinh trajectory tham số có ràng buộc động học từ phân bố state, rồi vocoder tạo sóng.

Biểu đồ minh họa: hmm_tracks.svg (SVG trong figures/).

5. Neural TTS và đánh giá

Không tải model ngẫu nhiên từ Internet. neural_tts_backend.py là adapter báo thiếu model; vì thế không tạo neural_tts.wav hay đo latency neural giả. Cần model offline được giảng viên cấp để hoàn tất mục F.

Bộ WAV hiện minh họa đúng định dạng và pipeline số, nhưng không có intelligibility/naturalness MOS hợp lệ. So sánh cần dùng cùng câu, loudness gần nhau, listening test tối thiểu 5 người và ghi ratings.csv. Latency cũng cần đo trên cùng máy.

Biểu đồ minh họa: waveform_outputs.svg (SVG trong figures/).

6. Trả lời và kết luận

1) Unit tự nhiên vẫn nghe kém tự nhiên vì prosody, ngữ cảnh, âm sắc và biên nối không khớp. 2) Target cost đo hợp ngữ cảnh; join cost đo độ êm biên; chỉ tối ưu join có thể chọn unit không phù hợp câu. 3) Cross-fade dài chồng lấn âm vị và làm mờ phụ âm.

4) F0 thuộc kích thích hữu thanh; formant chủ yếu do bộ lọc ống thanh quản. 5) PSOLA đổi khoảng cách pitch epoch; kéo dài hữu thanh quá mức gây buzz. 6) Delta feature làm mượt trajectory nhờ ràng buộc biến thiên. 7) Whole-waveform inventory cần bao phủ ngữ cảnh lớn. 8) Neural học ánh xạ văn bản-tham số/âm thanh, concatenative chọn và ghép mẫu. 9) Cần cố định model/version để tái lập. 10) MOS cao nhưng intelligibility thấp chỉ phù hợp âm thanh nền không cần nội dung chính xác.

Kết luận: các bước inventory, normalization, nối, chọn unit, smoothing và phân tích tham số có thể chạy lại; kết quả chất lượng tiếng nói thực và neural inference còn cần dữ liệu/model được cấp.